

Detecção de Fraude em Cartões

Resultados e Recomendações

DataRunk | Maio 2026

O que alcançamos

R\$ 242.000 a menos em fraudes por mês

O novo modelo detecta 8 em cada 10 fraudes antes de causar prejuízo — contra 6 em cada 10 anteriormente.

Em termos anuais, isso representa uma economia potencial de R\$ 2.9 milhões.

A tabela abaixo compara o desempenho do modelo anterior com o modelo atual em linguagem de negócio:

Indicador	Modelo anterior	Modelo atual
Fraudes detectadas	~6 em cada 10	8 em cada 10 ✓
Prejuízo mensal residual	R\$ 484.500	R\$ 242.250 ✓
Economia gerada	—	R\$ 242.000/mês ✓
Capacidade discriminativa (AUC)	~0.78	0.90 ✓

Nota: os valores acima são projeções baseadas em premissas conservadoras (50.000 transações/mês, ticket médio de R\$ 850, taxa de fraude de 3%). O impacto real deve ser calibrado com os dados operacionais da sua carteira.

Como o modelo toma decisões

O modelo analisa cada transação em tempo real e atribui uma probabilidade de fraude. Se essa probabilidade ultrapassa um determinado limite, um alerta é gerado para revisão.

Para chegar ao resultado acima, calibramos esse limite de forma a capturar o máximo de fraudes reais sem gerar alertas em excesso para a equipe de revisão. A tabela abaixo mostra como diferentes configurações afetam o resultado:

Sensibilidade	Alertas gerados	Fraudes capturadas	Impacto operacional
Baixa (0.5)	Menos alertas	~7 em 10	Menos trabalho de revisão, porém mais fraudes escapam
Escolhida (0.3)	Moderado	8 em 10 ✓	Equilíbrio ideal: custo de revisão menor que prejuízo evitado
Alta (0.2)	Muitos alertas	~9 em 10	Sobrecarga da equipe de revisão com falsos positivos

Por que escolhemos essa configuração: revisar um alerta indevido custa algumas dezenas de reais em tempo de analista. Uma fraude não detectada custa em média R\$ 850 em prejuízo direto — fora o impacto na confiança do cliente e eventuais chargebacks. A conta favorece claramente o lado da sensibilidade.

Riscos conhecidos e como os gerenciamos

Fraudes com padrões novos

Todo modelo aprende com o passado. Golpes com técnicas inéditas — novos esquemas de phishing, fraudes em canais recém-lançados — podem não ser reconhecidos imediatamente.

Como mitigamos: monitoramento mensal do desempenho em produção. Se a taxa de detecção cair mais de 5 pontos percentuais, o modelo é retreinado com dados recentes. Ciclo recomendado: revisão trimestral.

Fraudes de baixo valor e alta frequência

Golpes que operam com microtransações graduais (ex: testes de cartão com valores de R\$ 1,00) ficam abaixo do radar do modelo, pois não ativam os indicadores de desvio de padrão.

Como mitigamos: regras complementares de velocity check — por exemplo, bloquear automaticamente mais de 3 transações abaixo de R\$ 10 em menos de 1 hora. Essa camada é simples de implementar e não depende do modelo.

Próximos passos recomendados

Com base nos resultados obtidos, sugerimos a seguinte sequência de implementação:

- **1. Piloto em produção (30 dias):**
 - ativar o modelo em produção com monitoramento diário das métricas de detecção e volume de alertas.
- **2. Regras complementares (semana 2):**
 - implementar velocity check para transações de baixo valor em paralelo ao modelo.
- **3. Revisão de desempenho (mês 2):**
 - comparar resultado real com as projeções deste relatório e ajustar o limite de sensibilidade se necessário.
- **4. Retreinamento programado (trimestral):**
 - incorporar dados novos de produção para manter o modelo atualizado frente a padrões emergentes de fraude.